

ОТЧЁТ RL GPT2 LoRA

Цель: С помощью LoRA и алгоритма GRPO изменить вероятность генерации GPT-2 положительного отзыва на фильм.

Датасет

Ревью будут генерироваться на основе датасета IMDB. Этот датасет содержит англоязычные отзывы о фильмах с метками: 0 - отрицательный отзыв, 1 - положительный отзыв.

Базовая модель

В качестве базовой модели возьмём `lvwerra/gpt2-imdb` - GPT-2 fine-tuned на датасете IMDB.

RL обучение


Обучение функции награды

Алгоритм GRPO, реализованный в библиотеке `trl` из экосистемы Hugging Face, требует функции награды, которая будет определять направление обучения.

В качестве функции награды возьмём предобученный BERT `distilbert-base-cased`

Затем построим датасет на основе IMDB, который будет содержать пары положительного и отрицательного отзывов. И дообучим на этом датасете модель награды, чтобы она хорошо различала ревью и давала большую награду положительным отзывам.

Для этого использовался `trl.RewardTrainer`, снизу переведен график роста accuracy модели награды, выше accuracy - чаще правильное ранжирование ревью.




Обучение GPT-2 + LoRA

Для упрощения и ускорения процесса обучения использовалась LoRA поверх предобученного GPT-2. LoRA - это небольшая низкоранговая добавка к линейным слоям GPT-2, а следовательно обучение более стабильно и риск сломать модель ниже, так как добавка к базовой модели небольшая.

Реализация LoRA была взята из библиотеки `peft`, ранг LoRA равен 32.

Также для обучения через GRPO потребовалось создать датасет префиксов отзывов длиной в 2-8 токенов.



Графики обучения через trl.GRPOTrainer, логирование велось в wandb:



Влияние learning rate

Так как trl.GRPOTrainer использует линейный scheduler, то learning rate со временем убывает и скорость этого убывания влияет на характер сходимости, было обнаружено что более медленное уменьшение learning rate приводит к сходимости к большей средней награде, то есть к генерации более позитивных отзывов

Так как эксперимент с большим learning rate обучался дольше, то сравнение не совсем корректное, но видно что синяя кривая отделяется от желтой и идёт выше по размеру средней награды:



Сравнение базовой и RL модели

Для анализа влияния RL на вероятность генерации положительного отзыва через GPT-2, будем использовать большую модель RoBERTa: `siebert/sentiment-roberta-large-english`

На основе IMDB был создан датасет из 1500 префиксов ревью, длиной в 2-8 токенов, аналогично процедуре обучения через GRPO.

Затем эти ревью были независимо дописаны двумя моделями, а затем семантически оценены, процент положительных отзывов представлен в таблице:

Модель	Процент положительных отзывов
GPT-2	49.6%
GPT-2 + LoRA	57.1%

Видно что в результате RL обучения модель значительно чаще начала генерировать положительные отзывы.

Дальнейшие идеи

- Эксперименты с learning rate для поиска оптимального обучения
- Эксперименты с рангом LoRA